

OPTIMIZACIÓN Y EVALUACIÓN COMPARATIVA DE MÉTODOS DE DETECCIÓN DE PUNTOS DE CAMBIO BASADOS EN VENTANAS DESLIZANTES Y LA DISTANCIA DE WASSERSTEIN

Johan Alexander Álvarez Osorio
Diego Fernando Fonseca Valero
Nicolás Alberto Moreno Reyes

Cra. 49 N° 7 Sur-50
Universidad EAFIT
Medellín, Colombia

RESUMEN

En este artículo se propone y evalúa un esquema de detección de puntos de cambio basado en ventanas deslizantes y en la distancia de Wasserstein, comparando una formulación apoyada en distribuciones gaussianas obtenidas mediante reconstrucción del espacio de fases y otra basada en distribuciones empíricas. El desempeño de ambos métodos se optimiza mediante una búsqueda de hiperparámetros guiada por una función de costo que combina homogeneidad intra-segmento y penalización por complejidad, empleando la heurística de la pendiente para seleccionar el regularizador. La evaluación se realiza sobre series sintéticas AR(2) con un escenario que varía en media y dispersión, y otro que varía en los coeficientes autorregresivos. Los resultados muestran que, en el primer escenario, ambos enfoques presentan comportamientos muy similares y no se observan diferencias estadísticamente significativas en la medida F1. En contraste, para el segundo escenario el método gaussiano exhibe un mejor equilibrio entre precisión y exhaustividad, con una ventaja estadísticamente significativa en exhaustividad y medida F1 frente al enfoque empírico. En conjunto, los hallazgos indican que la representación gaussiana resulta especialmente ventajosa cuando los cambios afectan la estructura de autocorrelación del proceso, mientras que ambos métodos son semejantes cuando las modificaciones se concentran en la media y la dispersión.

1. INTRODUCCIÓN

El análisis de series de tiempo se ha consolidado como un campo fundamental tanto en la investigación como en la práctica, con un espectro cada vez más amplio de aplicaciones. Una serie de tiempo se define como una secuencia de observaciones registradas en instantes específicos y organizadas cronológicamente, caracterizada por componentes como tendencia, estacionalidad, cíclicidad y aleatoriedad [1]. Entre las metodologías más empleadas se encuentra la clasificación de series de tiempo, la cual requiere enfoques más avanzados que el uso de algoritmos tradicionales. Una estrategia consiste en transformar las series hacia otros espacios mediante la incorporación de información geométrica [2, 3, 4]. En particular, el teorema de Takens ha sido utilizado para segmentar series de tiempo y, a partir de ello, representarlas en variedades estadísticas. Bajo esta perspectiva, se ha explorado el uso de la matriz de covarianzas entre segmentos, lo que sitúa a la serie en la variedad de matrices simétricas semidefinidas positivas [2], así como el empleo

de proyecciones ortonormales derivadas de la matriz que conforman dichos segmentos para trabajar en la variedad de Stiefel [3].

Dentro de estas transformaciones hacia nuevos espacios, se emplean métodos de clasificación estándar que pueden dividirse en enfoques supervisados y no supervisados. Entre los más utilizados se encuentran los algoritmos de k-vecinos más cercanos (KNN), k medias (K-means), el agrupamiento basado en densidad (DBSCAN) y la clusterización espectral (Spectral Clustering) [5]. Estos métodos suelen emplearse como herramientas complementarias en la detección de puntos de cambio, un problema también ampliamente estudiado en el análisis de series temporales.

En este ámbito se han propuesto diversas aproximaciones. Sin embargo, algunas definiciones coinciden en que un punto de cambio en una serie de tiempo se define como el instante en el que la secuencia se segmenta en regiones mutuamente excluyentes. Dentro de cada región la serie mantiene un comportamiento homogéneo, mientras que entre regiones se observan diferencias significativas en su dinámica [6]. Algunos conceptos como segmentación o anomalía son similares al de punto de cambio, con la diferencia de que estos conceptos se refieren a eventos transitorios, mientras que un punto de cambio se caracteriza por su durabilidad [7, 8].

En la práctica, los puntos de cambio tienen un amplio rango de aplicaciones. Entre los ejemplos más relevantes se encuentran el monitoreo de condiciones médicas por medio de electrocardiogramas o electroencefalogramas, la detección de fallas en procesos de manufactura como anomalías en la producción o en las vibraciones de la maquinaria, la identificación de patrones de fraude en la localización o transacciones de una tarjeta de crédito, la detección de discontinuidades climáticas, el reconocimiento de voz, entre otros [6, 9, 10].

Específicamente, un punto de cambio puede ser detectado por cambios en el comportamiento estadístico de la serie de tiempo como en su media, en su varianza, en su periodicidad o en su autocorrelación [10]. Definiciones de este tipo de cambios de comportamiento se han explorado de manera más detallada [9], definiendo el cambio en la media como un movimiento en la tendencia central de los datos, en la dispersión como un cambio en la amplitud con la que fluctúan los datos entorno a la media, en la periodicidad como la modificación de la frecuencia con la que se repiten los ciclos o patrones estacionales de los datos y en la autocorrelación como la modificación en la forma en que los valores actuales dependen de los valores pasados.

Para formalizar la noción matemática de puntos de cambio, en [6] se plantea que una serie de tiempo puede entenderse como una secuencia de observaciones en la cual se identifican ciertos instantes específicos que dividen la serie en distintos segmentos. Estos instantes corresponden a los puntos de cambio y permiten particionar la secuencia en intervalos consecutivos que, en conjunto, abarcan la totalidad de los datos. Una formulación similar se presenta en [11], donde se muestra que los parámetros que gobiernan la intensidad de un Proceso de Poisson No Homogéneo experimentan modificaciones cada vez que se cruza un punto de cambio, lo que refleja alteraciones en la dinámica subyacente de ocurrencia de los eventos.

En este sentido, el problema de detección de puntos de cambio puede clasificarse en dos categorías: problemas en línea y problemas fuera de línea [10, 12]. Los problemas fuera de línea, el uso más común, es retrospectivo y toma la serie de tiempo completa para detectar los cambios. Por el contrario, los problemas en línea monitorean la serie de tiempo secuencialmente y detectan un punto de cambio tan pronto ocurre. En ambos casos, el uso de simulaciones en las que se conoce la posición y la cantidad de puntos de cambio resulta pertinente, ya que permite emplear métricas de aprendizaje supervisado, como la medida F1 o la exhaustividad, para evaluar el desempeño de los algoritmos [13]. Estas métricas han sido ampliamente utilizadas en la literatura para valorar la efectividad de los métodos de detección de puntos de cambio [9, 14].

Por su parte, desde el punto de vista metodológico en [14] se propone una clasificación de los algoritmos de detección de puntos de cambio fuera de línea basada en su formulación como problemas de optimización. De acuerdo con este artículo, la detección se plantea como la segmentación de la serie de tiempo tal que se maximice la homogeneidad dentro de cada segmento. Esto se logra mediante la minimización de una

función de costo que cuantifica la discrepancia o variabilidad intra-segmento. En consecuencia, un algoritmo de detección de puntos de cambio queda determinado por tres componentes fundamentales, los cuales son la función de costo que mide la calidad de cada segmentación, las restricciones o penalizaciones que regulan la complejidad del modelo, típicamente asociadas al número de cambios permitidos, y el método de búsqueda empleado para encontrar los puntos de cambio óptimos.

En particular, el método de búsqueda se divide entre métodos exactos y métodos aproximados. Según [14], los métodos aproximados se clasifican a su vez en segmentación binaria, segmentación de abajo hacia arriba y ventanas deslizantes. En este contexto, la segmentación binaria es un método voraz que identifica iterativamente el punto de cambio que mayor reducción produce en la función de costo y divide recursivamente la señal en subsegmentos. Por su parte, la segmentación de abajo hacia arriba inicia con múltiples subsegmentos pequeños y fusiona sucesivamente los más similares hasta alcanzar el número deseado de cambios. Finalmente, el método de ventanas deslizantes calcula una medida de discrepancia entre ventanas adyacentes que se desplazan a lo largo de la serie, detectando cambios donde dicha discrepancia es máxima. Este último enfoque, además, permite formular la detección de puntos de cambio como un problema de prueba de hipótesis.

De este modo, en la literatura se establece como hipótesis nula que las distribuciones de probabilidad asociadas a las ventanas de la serie permanecen inalteradas, mientras que la hipótesis alternativa supone la existencia de un instante particular a partir del cual la distribución cambia, lo que marcaría la presencia de un punto de cambio [7]. De manera complementaria, se formula una prueba de hipótesis centrada en características estadísticas específicas de la serie [9], tales como la media, la varianza, la periodicidad o la autocorrelación. En este caso, la hipótesis nula sostiene que ninguno de los valores de la serie sobrepasa un umbral previamente definido, en tanto que la hipótesis alternativa considera la posibilidad de que al menos en un instante dicho límite sea superado.

Sobre este hecho, el uso de distribuciones empíricas en las ventanas anteriores y posteriores a un punto ha sido estudiado. Algunas aproximaciones consisten en calcular la distancia de Wasserstein, también conocida como distancia de Mallows, y establecer un umbral tal que si la distancia entre las distribuciones empíricas de las ventanas es inferior no se rechaza la hipótesis nula de que la distribución de los datos ha cambiado [15, 16]. En consecuencia, no se encuentra evidencia de un punto de cambio.

La determinación del umbral para aceptar o rechazar la hipótesis nula se ha abordado mediante el remuestreo con reemplazo (bootstrap) de los datos de las ventanas [17]. Este procedimiento permite estimar la distribución del estadístico, en este caso la distancia de Wasserstein, y fijar un cuantil que funcione como región de rechazo. Asimismo, en [18] se establece un umbral alternativo a partir del límite en distribución del estadístico de dos muestras bajo la hipótesis nula. En particular, se demuestra que el estadístico de prueba converge en distribución hacia una integral de un movimiento browniano estandarizado, lo que permite definir un umbral explícito. Además, este mismo trabajo propone una clasificación de los puntos de cambio mediante la partición de la serie en segmentos delimitados por dichos puntos. Sobre estos segmentos se construye una matriz de similitud, donde la métrica utilizada es la distancia de Wasserstein, y a partir de ella se aplica clusterización espectral para agrupar los puntos de cambio.

Esta metodología resulta atractiva para la detección de puntos de cambio. Sin embargo, la estimación de tamaños de ventana óptimos que garanticen homogeneidad intra-segmento para una función de costo dada ha sido escasamente estudiada. Asimismo, la incorporación de enfoques de clasificación de series de tiempo que consideran explícitamente la estructura de dependencia temporal, como aquellos basados en el teorema de Takens, podría mejorar significativamente el desempeño en comparación con métodos fundamentados únicamente en distribuciones empíricas, pues bajo el supuesto de normalidad y empleando el teorema de Takens es posible aprovechar que la distancia de Wasserstein entre distribuciones normales admite una expresión en forma cerrada, lo que simplifica considerablemente su implementación [19]. En una fase anterior se exploró la utilidad del teorema de Takens para la detección de puntos de cambio, aprovechando la forma cerrada de la distancia de Wasserstein entre distribuciones normales y observando un desempeño favorable en casos particulares. En la presente fase se busca realizar una validación rigurosa

del algoritmo mediante un análisis experimental que permita establecer la significancia estadística de los resultados obtenidos. Teniendo presente lo anterior la hipótesis del proyecto es que el método de detección de puntos de cambio basado en ventanas deslizantes que emplea la transformación de series de tiempo a distribuciones gaussianas supera en al menos un 5% la medida F1 del método equivalente basado en distribuciones empíricas bajo un mismo esquema de optimización de hiperparámetros.

1.1. Objetivos

Para comprobar la hipótesis de investigación previamente expuesta se plantea un objetivo general complementado con tres objetivos específicos que orientan la elaboración del trabajo.

1.1.1. Objetivo General

Evaluar un modelo de optimización de hiperparámetros para algoritmos de detección de puntos de cambio basados en ventanas deslizantes, mediante el diseño de una función de costo que cuantifique la homogeneidad intra-segmento entre los puntos delimitados por cambios detectados con el fin de comparar el desempeño de ambos algoritmos bajo sus condiciones óptimas utilizando métricas estándar de evaluación.

1.1.2. Objetivos Específicos

- Diseñar un conjunto de pruebas simuladas que generen series de tiempo con distintas características estructurales, por medio de la implementación de modelos autorregresivos y de media móvil, para la evaluación del desempeño de los algoritmos de detección de puntos de cambio bajo diferentes escenarios.
- Realizar una prueba de hipótesis sobre 200 ejecuciones de cada algoritmo de detección de puntos de cambio en cada escenario simulado, comparando la métrica F1 para determinar si las diferencias observadas son estadísticamente significativas.
- Visualizar los resultados de la detección de puntos de cambio en series de tiempo representativas de cada escenario simulado, mediante la construcción de gráficas que distingan los puntos de cambio reales y los identificados por cada algoritmo para ilustrar comparativamente su desempeño en cada caso.

2. MÉTODOS

Los métodos propuestos se estructuran en dos subsecciones principales. En primer lugar, en la subsección (2.1) se presenta el algoritmo de detección de puntos de cambio basado en ventanas deslizantes sobre una serie de tiempo univariada. En segundo lugar, en la subsección (2.2) se aborda la calibración de los parámetros requeridos por dicho algoritmo, con el fin de optimizar su desempeño. Esta calibración se formula como un problema de optimización discreta, cuya solución se obtiene mediante búsqueda exhaustiva o el uso de metaheurísticas. Cabe destacar que una de las propuestas (la basada en distribuciones gaussianas) asume que la serie temporal proviene de la observación de una variable asociada a un sistema dinámico, y que las representaciones de las ventanas pueden aproximarse mediante distribuciones normales. En general, ambos enfoques presentan ciertas limitaciones, entre las que se incluyen la imposibilidad de detectar cambios en las primeras y últimas ventanas, así como la necesidad de contar con series de longitud suficiente, considerando adecuadas series del orden de por lo menos 30 observaciones por punto de cambio para garantizar su aplicabilidad. Además, el uso de búsqueda exhaustiva necesario en la calibración de hiperparámetros lo hace poco escalable. Finalmente, dado que el objetivo principal es contrastar ambos procedimientos de detección, en las subsecciones (2.3) y (2.4) se introducen las simulaciones y las métricas empleadas para cuantificar su desempeño.

2.1. Detección de Puntos de Cambio

Para formular el problema de detección de puntos de cambio, se considera una serie de tiempo univariada de longitud N , denotada por $y = \{y_1, y_2, \dots, y_N\}$. Siguiendo la notación de [14], un segmento de esta serie comprendido entre los índices a y b , con $1 \leq a < b \leq N$, se representa como $y_{a:b} = \{y_a, y_{a+1}, \dots, y_b\}$.

El objetivo consiste en identificar un conjunto de índices $\mathcal{T} = \{t_1, \dots, t_k\} \subset \{1, \dots, N\}$, correspondientes a los puntos de cambio, de tal manera que la serie completa pueda descomponerse en una sucesión ordenada de segmentos consecutivos. Es decir, se busca que la unión de estos segmentos reconstruya la serie original:

$$\bigcup_{1 \leq i < k} y_{t_i:t_{i+1}} := y$$

Con el fin de abordar este problema se propone definir una ventana deslizante de tamaño n como $w^i = \{y_{i+1}, y_{i+2}, \dots, y_{i+n}\}$, con $N \geq n$, de modo que el conjunto $\{w^1, w^2, \dots, w^{N-n}\}$ corresponde a todas las subsecuencias consecutivas de longitud n que recorren la serie y . De esta forma, para un índice $\alpha \in \{n+1, n+2, \dots, N-n\}$, se comparan las distribuciones de probabilidad asociadas a las ventanas inmediatamente anterior y posterior a este índice, es decir, $\mathbb{P}(w^{\alpha-n})$ y $\mathbb{P}(w^\alpha)$. Si se observa una diferencia significativa entre ambas, el instante α se identifica como un punto de cambio en la serie y [7].

Para medir la diferencia entre dos distribuciones de probabilidad se utiliza la distancia de Wasserstein, también conocida como distancia del transporte óptimo. Como se evidencia en las ecuaciones (1) y (2), dadas dos distribuciones $p_1(\cdot)$ y $p_2(\cdot)$, esta métrica se define como el costo mínimo necesario para transformar una distribución en la otra, considerando todas las maneras posibles de trasladar la masa de probabilidad [20].

$$W(p_1(x), p_2(y)) = \min_{\pi \in \Pi} \int_x \int_y \|x - y\|^2 \pi(x, y) dx dy, \quad (1)$$

$$\int_y \pi(x, y) dy = p_1(x), \quad \int_x \pi(x, y) dx = p_2(y) \quad (2)$$

Con el fin de medir esta diferencia significativa bajo la cual se considera un punto de cambio, se define

$$W(\alpha) = W(\mathbb{P}(w^{\alpha-n}), \mathbb{P}(w^\alpha)),$$

de donde se obtiene una curva que representa la distancia de Wasserstein en función de cada punto de la serie temporal en el conjunto

$$\{\alpha \mid \alpha = n+1, n+2, \dots, N-n\}.$$

Dado que esta curva puede presentar un alto nivel de rugosidad, en lugar de aplicar un suavizamiento previo se identifican directamente los máximos locales de $W(\alpha)$ y se filtran mediante dos criterios complementarios: la prominencia del pico y una distancia mínima entre picos consecutivos. Así, un estimador para el conjunto de puntos de cambio $\mathcal{T}$ puede definirse como

$$\widehat{\mathcal{T}} = \mathcal{S}_{n, \lambda_p}(W(\alpha)), \quad (3)$$

donde $\mathcal{S}_{n, \lambda_p}$ denota el operador que conserva únicamente aquellos máximos locales cuya prominencia excede un umbral λ_p y cuya separación respecto de otros máximos retenidos es al menos n .

Formalmente, si $\mathcal{P}$ denota el conjunto de máximos locales de la curva $W(\alpha)$, la prominencia de un pico en α se define como

$$\text{Prom}(\alpha) = W(\alpha) - \max\{B_L(\alpha), B_R(\alpha)\}, \quad (4)$$

donde $B_L(\alpha)$ y $B_R(\alpha)$ representan, respectivamente, las bases izquierda y derecha del pico, entendidas como los mínimos alcanzados al descender desde dicho máximo hasta encontrar una cota superior o el

borde de la señal. En consecuencia, la regla de selección de picos puede escribirse como

$$\text{Pico}(W(\alpha)) = \begin{cases} W(\alpha), & \text{si } \alpha \in \mathcal{P}, \text{ Prom}(\alpha) \geq \lambda_p, \text{ y } |\alpha - \beta| \geq n \text{ para todo } \beta \in \widehat{\mathcal{T}}, \\ 0, & \text{en otro caso.} \end{cases} \quad (5)$$

La condición de prominencia permite conservar aquellos máximos que sobresalen estructuralmente respecto a su entorno local, mientras que la restricción de distancia mínima evita la detección múltiple de un mismo evento de cambio, el cual suele generar un racimo de máximos cercanos en la curva de Wasserstein. De esta manera, los puntos de cambio detectados corresponden a variaciones significativas en la dinámica de la serie, sin requerir un suavizamiento previo de la señal.

En este sentido, uno de los enfoques propuestos se basa en un supuesto de normalidad. Este enfoque dispone principalmente del teorema de Takens, para el cual es necesario partir de la observación de una variable de un sistema dinámico, en este caso la serie de tiempo. De acuerdo con el teorema de Takens, de la observación de esta única variable es posible reconstruir su espacio de fases completo [20]. En consecuencia, se asume que la serie y corresponde a la medición de una de las variables de dicho sistema y por tanto puede emplearse para generar una reconstrucción del espacio de fases. En este contexto, cada vector definido como en (6) representa una observación del sistema dinámico de dimensión m , a partir del cual la serie y tiene su origen.

$$x_i = \{y_i, y_{i+\tau}, y_{i+2\tau}, \dots, y_{i+(m-1)\tau}\} \quad (6)$$

De concatenar cada vector para todas las $i \in \{1, 2, \dots, N - (m-1)\tau\}$ se obtiene la matriz de trayectoria [3], con dimensión $N - (m-1)\tau \times m$ y que tiene la forma dada en (7).

$$T_y = \begin{bmatrix} y_1 & y_{1+\tau} & \cdots & y_{1+(m-1)\tau} \\ y_2 & y_{2+\tau} & \cdots & y_{2+(m-1)\tau} \\ \vdots & \vdots & \ddots & \vdots \\ y_k & y_{k+\tau} & \cdots & y_{k+(m-1)\tau} \\ \vdots & \vdots & \ddots & \vdots \\ y_{N-(m-1)\tau} & y_{N-(m-2)\tau} & \cdots & y_N \end{bmatrix} \quad (7)$$

Por ello, al denotar por T_w la matriz de trayectoria asociada a una ventana w , se asume que el vector de estado correspondiente a dicha ventana sigue una distribución normal multivariada, como se muestra en (8). En particular, esta distribución se caracteriza por una media $\mu(T_w)$ y una matriz de covarianza $\Sigma(T_w)$, donde $\mu(\cdot)$ y $\Sigma(\cdot)$ representan, respectivamente, la media y la matriz de covarianza de la matriz de trayectoria.

$$w_m^\alpha \sim \mathcal{N}(\mu(T_{w^\alpha}), \Sigma(T_{w^\alpha})) \quad (8)$$

Cabe destacar que w_m denota una ventana de dimensión m , es decir, una representación multivariada que no solo incluye los valores de la ventana w^α de la serie original y , sino también $m-1$ componentes adicionales asociadas a la reconstrucción del espacio de estados. De lo anterior, resulta que $W(\mathbb{P}(w_m^{\alpha-n}), \mathbb{P}(w_m^\alpha))$ es de la forma cerrada que se ve en (9) tal y como se demuestra en [19]. En este caso siguen aplicando las ecuaciones (3) y (5), redefiniendo $W(\alpha) = W(\mathbb{P}(w_m^{\alpha-n}), \mathbb{P}(w_m^\alpha))$.

Para el método basado en distribuciones empíricas se emplea la misma metodología descrita en [18]. Por otra parte, aunque en la revisión comparativa presentada en [9] se utiliza el test de Friedman para el análisis estadístico de la métrica F1 entre múltiples métodos, en este trabajo se opta por el test no paramétrico de Wilcoxon, dado que únicamente se realiza la comparación entre dos métodos.

$$W(p_1, p_2) = \|\mu_1 - \mu_2\|^2 + \text{tr}(\Sigma_1) + \text{tr}(\Sigma_2) - 2 \text{tr} \left(\left(\Sigma_1^{1/2} \Sigma_2 \Sigma_1^{1/2} \right)^{1/2} \right). \quad (9)$$

2.2. Calibración de hiperparámetros

Cuando el problema de detección de puntos de cambio se formula como un problema de optimización en el que el número de cambios es desconocido, resulta necesario definir una función objetivo compuesta por dos términos [14]. Por un lado, un costo asociado a cada segmento, el cual cuantifica la homogeneidad de las observaciones dentro de dicho segmento. Por otro lado, un término de penalización que regula la complejidad del modelo, evitando la sobreestimación del número de puntos de cambio. Este problema de optimización queda planteado como:

$$\min_{\mathcal{T}} \sum_{i=1}^k c(y_{t_i:t_{i+1}}) + \gamma \text{pen}(\mathcal{T}) \quad (10)$$

Dado que los algoritmos de detección de puntos de cambio propuestos (tanto el basado en el supuesto gaussiano como el enfoque empírico) no imponen supuestos paramétricos sobre la distribución de la serie, el problema se enmarca en un contexto no paramétrico. En consecuencia, se adopta como función de costo la entropía de la distribución empírica de los segmentos detectados y como penalización la cantidad de puntos de cambio detectados, siguiendo el enfoque propuesto en [21].

El problema de optimización dado en (10) puede reformularse para los algoritmos de detección de puntos de cambio basados en ventanas deslizantes como:

$$\min_{\mathcal{P}} \sum_{i=1}^k c(y_{t_i:t_{i+1}}, \mathcal{P}) + \gamma |\widehat{\mathcal{T}}_{\mathcal{P}}| \quad (11)$$

Donde $\mathcal{P}$ corresponde al conjunto de parámetros del algoritmo, $c(y_{t_i:t_{i+1}}, \mathcal{P})$ a la entropía entre dos segmentos dependientes de los parámetros del algoritmo, γ al regularizador y $|\widehat{\mathcal{T}}_{\mathcal{P}}|$ la cantidad de puntos de cambio detectados por el algoritmo para un conjunto de parámetros dado. Para estimar el valor del parámetro de regularización γ se realiza una búsqueda exhaustiva sobre el conjunto de parámetros $\mathcal{P}$, evaluando para cada configuración el par $(|\widehat{\mathcal{T}}_{\mathcal{P}}|, \sum_{i=1}^k c(y_{t_i:t_{i+1}}, \mathcal{P}))$. Esto permite construir una relación empírica entre el costo y la complejidad del modelo, medida por el número de puntos de cambio detectados. A partir de estos pares, se define la frontera de Pareto empírica, reteniendo únicamente aquellas configuraciones que logran el menor costo posible para cada nivel de complejidad.

Sobre esta frontera, se observan típicamente dos regímenes. En el régimen de sub-ajuste, incrementos en $|\widehat{\mathcal{T}}_{\mathcal{P}}|$ producen reducciones significativas en el costo al capturar estructura real de la serie. En contraste, en el régimen de sobre-ajuste, las mejoras en el costo son aproximadamente lineales y responden únicamente al ajuste del ruido.

La heurística de la pendiente consiste en identificar este régimen lineal y estimar su pendiente mediante una regresión sobre la cola de la curva. Esta pendiente proporciona una estimación de la penalización mínima, y el valor óptimo del regularizador se obtiene como el doble de dicha pendiente. En consecuencia, γ se calibra en función de los datos, logrando un balance adecuado entre el ajuste a los datos y la complejidad del modelo [22]. Dado que la heurística de la pendiente permite obtener, a partir de la búsqueda exhaustiva sobre $\mathcal{P}$, un conjunto de valores del costo y de la complejidad (penalización) asociados a cada configuración, la selección final de $\mathcal{P}$ se realiza minimizando la función objetivo penalizada. En particular, una vez estimado el valor de γ mediante dicha heurística, se determina el conjunto óptimo de parámetros como aquel que minimiza la suma del costo empírico y el término de penalización ponderado por γ . La cola de la curva se determina identificando el codo de la misma. En vista de que la experimentación se realiza en múltiples ocasiones, la identificación del codo se hace automatiza siguiendo el procedimiento descrito en [23].

2.3. Simulación de series de tiempo

Para la generación de bases de datos sintéticas orientadas a la evaluación de algoritmos de detección de puntos de cambio es común recurrir a modelos autorregresivos de media móvil. Específicamente, en

[9] se propone introducir variaciones en la media, la dispersión y los coeficientes autorregresivos de la serie. Con el fin de extender este enfoque e incorporar también la componente de media móvil, una serie de tiempo generada bajo esta metodología puede describirse de la siguiente manera:

$$y_i = \beta_1 * y_{i-1} + \beta_2 * y_{i-2} + \theta_1 * \varepsilon_{i-1} + \theta_2 * \varepsilon_{i-2} + \varepsilon_i \quad \varepsilon_i \sim \mathcal{N}(\mu, \sigma^2) \quad (12)$$

Una variación en uno o varios de los parámetros $(\beta_1, \beta_2, \theta_1, \theta_2, \mu, \sigma)$ define la ocurrencia de un punto de cambio. Asimismo, con el fin de seguir el procedimiento propuesto en [9], se introduce ruido adicional en la serie de tiempo cada 200 instantes, con el objetivo de incrementar la variabilidad y evaluar la robustez del algoritmo.

2.4. Evaluación de desempeño

Tomando en cuenta que $\mathcal{T}$ es el conjunto de puntos de cambio verdaderos, entonces $\widehat{\mathcal{T}}$ define el conjunto de puntos de cambio detectados por un método. Para medir la localización se fija un umbral de tolerancia δ . Para cada punto verdadero $\alpha \in \mathcal{T}$ definimos la distancia al punto de cambio más cercano como

$$d(\alpha) = \min_{\alpha^* \in \widehat{\mathcal{T}}} |\alpha^* - \alpha|. \quad (13)$$

Con esta variable construimos el conjunto de distancias emparejadas por debajo del umbral:

$$D(\delta) = \{d(\alpha) : \alpha \in \mathcal{T}, d(\alpha) \leq \delta\}, \quad (14)$$

y definimos el promedio de las distancias sobre los verdaderos positivos (promedio solo sobre los elementos de $D(\delta)$) como:

$$\bar{d}(\delta) = \frac{1}{|D(\delta)|} \sum_{d \in D(\delta)} d \quad (15)$$

Esta variable resume el error de localización medio. A partir de (14) definimos las siguientes cantidades (dependientes de δ):

$$TP(\delta) = |D(\delta)|, \quad (16)$$

$$FP(\delta) = |\{\alpha^* \in \widehat{\mathcal{T}} : \forall \alpha \in \mathcal{T}, |\alpha^* - \alpha| > \delta\}|, \quad (17)$$

$$FN(\delta) = |\mathcal{T}| - TP(\delta). \quad (18)$$

Donde en (16) se define la cantidad de verdaderos positivos, entendidos como la cardinalidad del conjunto de distancias emparejadas que se encuentran dentro del umbral δ . En (17) se define la cantidad de falsos positivos y en (18) la de falsos negativos.

A partir de estas cantidades se calculan las métricas de precisión, exhaustividad (recall en inglés) y puntaje F_1 [13], que permiten evaluar la calidad de la detección y que han sido utilizadas con frecuencia en artículos de revisión de algoritmos de detección de puntos de cambio [9, 14]. Estas métricas se formulan como se muestra a continuación:

$$PRE = \frac{TP}{FP + TP} \quad (19)$$

$$REC = \frac{TP}{FN + TP} \quad (20)$$

$$F1 = 2 \times \frac{PRE \times REC}{PRE + REC} \quad (21)$$

Donde (19) y (20) corresponden a la precisión y a la exhaustividad respectivamente. De manera complementaria, se reporta el promedio de localización $\bar{d}(\delta)$, dado en (15), como medida del error espacial de las detecciones correctamente emparejadas.

3. RESULTADOS

Los resultados obtenidos a partir de la aplicación del modelo propuesto y del método de referencia [18] sobre dos series simuladas se organiza en correspondencia con la estructura metodológica previamente descrita. En primer lugar, se presentan los parámetros utilizados para simular las series de tiempo de manera análoga a las diseñadas en [9]. Posteriormente los resultados de la detección de puntos de cambio, donde se comparan ambos enfoques, tanto en las métricas medias obtenidas como por pruebas de hipótesis para determinar su relevancia estadística. Esta estructura permite contrastar el desempeño de cada componente del modelo y evidenciar la coherencia entre los resultados obtenidos y cada uno de los objetivos planteados.

3.1. Configuración Experimental

Con el propósito de evaluar el desempeño de ambos métodos bajo distintos escenarios dinámicos, se simularon dos procesos autorregresivos de orden dos. En el primer experimento se introducen variaciones en la media y en la dispersión de la serie temporal, mientras que en el segundo se consideran cambios en la estructura de autocorrelación mediante la variación de los coeficientes autorregresivos. La configuración detallada de los parámetros empleados en cada experimento se presenta en la Tabla 1.

Tabla 1: Parámetros utilizados en los experimentos sobre procesos AR(2).

Experimento	N	μ	σ	β_1	β_2	$\ \mathcal{T}\ $
AR(2) media y dispersión fluctuantes	2000	[0.3, 3]	[0.3, 1.2]	0.3	0.5	20
AR(2) rezagos fluctuantes	2000	0.5	[0.3, 1.2]	[-0.9, 0.9]	[-0.9, 0.9]	20

Adicionalmente, con el fin de incorporar perturbaciones exógenas y aumentar la complejidad de los escenarios simulados, cada 200 instantes de tiempo se añade a la serie un término de ruido generado aleatoriamente.


Por otro lado, como se mencionó previamente, los parámetros de los algoritmos fueron calibrados de manera automática. No obstante, siguiendo los resultados reportados en [3], la dimensión de incrustación m se fijó en 3, ya que los experimentos realizados por los autores evidencian que este parámetro tiene una influencia limitada sobre la capacidad discriminativa del método para distinguir diferentes series temporales.

En cuanto a la detección de puntos de cambio, el umbral de prominencia utilizado para seleccionar los máximos locales de la curva de distancias se definió como el percentil 5 % de las prominencias observadas en cada ejecución. De esta manera, únicamente se conservan aquellos picos cuya prominencia supera dicho valor de referencia. Adicionalmente, durante la etapa de detección de máximos locales se impuso una separación mínima entre picos consecutivos igual al tamaño de ventana n empleado en el cálculo de las distancias. Esta restricción evita la detección de múltiples máximos asociados a una misma transición estructural y favorece la identificación de un único punto representativo por cambio de régimen.


Por último, la tolerancia de emparejamiento utilizada en la evaluación de los puntos de cambio detectados se fijó en $\delta = 30$, valor que determina la máxima separación permitida entre un punto de cambio real y uno estimado para considerarlos coincidentes.

3.2. Experimento AR(2) con media y dispersión fluctuantes


Las Figuras 1 y 2 presentan los resultados obtenidos para los métodos Gaussiano y Empírico, respectivamente, sobre una realización del experimento AR(2) con media y dispersión variables. En ambos casos se muestra la serie de tiempo junto con la distancia de Wasserstein utilizada como criterio de detección, así como la comparación entre los puntos de cambio originales y los detectados. Adicionalmente, se incluyen las curvas del frente de Pareto empleadas en la selección del parámetro de regularización mediante la heurística de la pendiente, identificando explícitamente el codo. Finalmente, se da una representación del comportamiento del costo respecto a los parámetros asociados a cada uno de los métodos.



(a) Serie de tiempo superpuesta con la distancia de Wasserstein y comparación entre los puntos de cambio originales y los detectados.




(b) Curva del frente de Pareto empírico utilizada para la selección del regularizador mediante la heurística de la pendiente.




(c) Mapa de calor del costo en función del tamaño de ventana y el retardo temporal.


Figura 1: Resultados obtenidos por el método Gaussiano sobre una realización del experimento AR(2) con media y dispersión variables.



(a) Serie de tiempo superpuesta con la distancia de Wasserstein y comparación entre los puntos de cambio originales y los detectados.




(b) Curva del frente de Pareto empírico utilizada para la selección del regularizador mediante la heurística de la pendiente.




(c) Dispersión del costo en función del tamaño de ventana.

Figura 2: Resultados obtenidos por el método Empírico sobre una realización del experimento AR(2) con media y dispersión variables.

La Figura 3 presenta una comparación estadística entre los métodos Gaussiano y Empírico sobre 200 experimentos AR(2) con media y dispersión variables. Mediante gráficos de violín se analiza la distribución de las métricas de desempeño F1-score, precisión y exhaustividad, así como el error medio de localización de los puntos de cambio detectados. Esta representación permite evaluar no solo el desempeño promedio de cada método, sino también la variabilidad y dispersión de los resultados obtenidos en los diferentes escenarios simulados. Por su parte, la Tabla 2 muestra los valores promedio y resultados de la prueba de hipótesis de Wilcoxon para los 200 experimentos en cada una de las métricas.



(a) Comparación de métricas F1-score, precisión y exhaustividad.



(b) Comparación del error medio de localización.

Figura 3: Gráficos de violines comparativos entre los métodos Gaussiano y Empírico sobre 200 experimentos AR(2) con media y dispersión variables.


Tabla 2: Comparación estadística de métricas entre los modelos Gaussiano y Empírico sobre 200 experimentos con media y dispersión variables ($\alpha = 0.05$).

Métrica	Promedio Gaussiano	Promedio Empírico	p -valor	Diferencia estadística	Mejor método
Error Medio de Localización	7.90	7.96	0.75	No	Sin diferencia
Precisión	0.87	0.88	0.99	No	Sin diferencia
Exhaustividad	0.81	0.81	0.80	No	Sin diferencia
Medida F1	0.83	0.83	0.74	No	Sin diferencia


3.3. Experimento AR(2) con rezagos fluctuantes

Al igual que en la subsección anterior, las Figuras 4, 5 y 6 presentan el comportamiento de los métodos Gaussiano y Empírico mediante la visualización de la serie temporal, la distancia de Wasserstein, la detección


de puntos de cambio y las métricas estadísticas de desempeño. Sin embargo, en este caso los experimentos se desarrollan sobre procesos AR(2) con coeficientes autorregresivos variables, de modo que los cambios introducidos en la serie afectan principalmente la estructura de autocorrelación y los rezagos del proceso, en lugar de modificar directamente la media y la dispersión.



(a) Serie de tiempo superpuesta con la distancia de Wasserstein y comparación entre los puntos de cambio originales y los detectados.




(b) Curva del frente de Pareto empírico utilizada para la selección del regularizador mediante la heurística de la pendiente.




(c) Mapa de calor del costo en función del tamaño de ventana y el retardo temporal.


Figura 4: Resultados obtenidos por el método Gaussiano sobre una realización del experimento AR(2) con rezagos variables.



(a) Serie de tiempo superpuesta con la distancia de Wasserstein y comparación entre los puntos de cambio originales y los detectados.




(b) Curva del frente de Pareto empírico utilizada para la selección del regularizador mediante la heurística de la pendiente.




(c) Dispersión del costo en función del tamaño de ventana.

Figura 5: Resultados obtenidos por el método Empírico sobre una realización del experimento AR(2) con rezagos variables.



(a) Comparación de métricas F1-score, precisión y exhaustividad.



(b) Comparación del error medio de localización.

Figura 6: Gráficos de violines comparativos entre los métodos Gaussiano y Empírico sobre 200 experimentos AR(2) con rezagos variables.

Tabla 3: Comparación estadística de métricas entre los modelos Gaussiano y Empírico sobre 200 experimentos con rezagos variables ($\alpha = 0.05$).

Métrica	Promedio Gaussiano	Promedio Empírico	p -valor	Diferencia estadística	Mejor método
Error Medio de Localización	8.07	7.82	0.08	No	Sin diferencia
Precisión	0.84	0.88	0.00	Sí	Empírico
Exhaustividad	0.71	0.64	0.00	Sí	Gaussiano
Medida F1	0.75	0.71	0.01	Sí	Gaussiano

4. DISCUSIÓN

Las simulaciones realizadas sobre series de tiempo AR(2) permiten observar que ambos enfoques son capaces de detectar adecuadamente cambios estructurales en la serie temporal, incluso bajo escenarios

donde la dinámica del proceso varía considerablemente. En particular, las representaciones de la distancia de Wasserstein en los casos preliminares muestran que tanto el método Gaussiano como el Empírico logran resaltar de forma consistente las regiones asociadas a cambios en la distribución subyacente de la serie. En el primer experimento, las Figuras 1a y 2a evidencian un adecuado alineamiento entre los puntos de cambio detectados y los originales, comportamiento que también se observa en el segundo experimento a partir de las Figuras 4a y 5a. Aunque no es posible generalizar conclusiones a partir de una única realización, los resultados sugieren que los tamaños de ventana óptimos tienden a ubicarse en un rango aproximado entre 30 y 60 observaciones.

Los mapas de calor (Figuras 1c y 4c) y los gráficos de dispersión (2c y 5c) asociados al costo muestran además que el desempeño de ambos métodos depende significativamente de la selección del tamaño de ventana y del retardo temporal. Se observa que regiones relativamente estables del espacio de parámetros producen mínimos de costo bien definidos, lo que indica que la metodología de optimización implementada permite identificar configuraciones robustas para la detección. Asimismo, las curvas del frente de Pareto (Figura 1b, 2b, 4b y 5b) evidencian que la heurística de la pendiente constituye un criterio adecuado para la selección del parámetro de regularización, evitando tanto el sobreajuste como la subdetección de puntos de cambio.

Ahora bien, las diferencias entre ambos métodos se hacen más evidentes al analizar conjuntamente las métricas de desempeño y la estabilidad de los resultados. En los experimentos donde se modifican la media y la dispersión, el método Gaussiano presenta una detección ligeramente más estable y una localización más precisa de los puntos de cambio, lo cual se refleja en menores errores medios de localización y distribuciones menos dispersas en los gráficos de violín, como puede observarse en la Figura 3b. No obstante, esta diferencia parece ser reducida. De hecho, al analizar las métricas F1, precisión y exhaustividad de la Figura 3a, se aprecia que, aunque las métricas de precisión y exhaustividad presentan una dispersión ligeramente menor para el método empírico, ambos enfoques mantienen desempeños globales semejantes en términos de medida F1. En consecuencia, la Tabla 2 muestra que, para un nivel de significancia del 5 %, no existe evidencia estadísticamente suficiente para afirmar diferencias relevantes entre ambos métodos.

Por otro lado, el experimento con rezagos variables exhibe un comportamiento similar en el error medio de localización de los puntos de cambio (Figura 6b), aunque se observan diferencias más marcadas en el desempeño de las demás métricas (Figura 6a). En particular, la Tabla 3 evidencia que, para un nivel de significancia del 5 %, el método Gaussiano supera al método Empírico en exhaustividad y medida F1, mientras que el método Empírico obtiene mejores resultados en precisión. Este comportamiento sugiere que el método Empírico tiende a ser más conservador en la detección, produciendo una menor proporción de falsos positivos, mientras que el enfoque Gaussiano logra un mejor equilibrio entre precisión y exhaustividad, reflejado en valores superiores de exhaustividad y medida F1. Desde la perspectiva de la detección de puntos de cambio, estas diferencias estadísticas indican que el método Gaussiano presenta una mayor capacidad para identificar correctamente los cambios reales presentes en la serie temporal cuando las alteraciones afectan la estructura de autocorrelación del proceso, aunque a costa de introducir una cantidad ligeramente mayor de detecciones adicionales.

Los resultados obtenidos permiten concluir que la hipótesis planteada no se verifica en el experimento asociado a variaciones en la media y la dispersión de la serie temporal. Aunque el método Gaussiano presenta, en promedio, un comportamiento ligeramente más estable y una menor dispersión en algunas métricas, las diferencias observadas respecto al método Empírico no resultan estadísticamente significativas para un nivel de significancia del 5 %. Adicionalmente, las medidas de desempeño obtenidas para ambos enfoques son considerablemente cercanas, particularmente en términos de medida F1, por lo que no puede afirmarse que el método basado en distribuciones gaussianas supere en al menos un 5 % al método basado en distribuciones empíricas bajo este tipo de perturbaciones. Esto sugiere que, cuando los cambios afectan principalmente momentos estadísticos globales como la media y la varianza, ambos enfoques poseen capacidades similares para detectar cambios estructurales.

Por el contrario, en el experimento donde las modificaciones afectan la estructura de autocorrelación mediante variaciones en los coeficientes autorregresivos, sí se observa una ventaja más clara del método Gaussiano. En este escenario, las diferencias en exhaustividad y medida F1 respecto al método Empírico resultan estadísticamente significativas, evidenciando una mayor capacidad del enfoque Gaussiano para equilibrar precisión y exhaustividad en la detección de puntos de cambio. En particular, la mejora observada en la medida F1 respalda la hipótesis del proyecto, indicando que la representación mediante distribuciones gaussianas puede capturar de manera más eficiente alteraciones en la dinámica temporal del proceso cuando los cambios se manifiestan en la dependencia entre observaciones y no únicamente en los momentos marginales de la distribución.

Como trabajo futuro, resulta de interés extender el análisis hacia la clasificación de los regímenes identificados entre puntos de cambio, así como estudiar la incorporación de ambos métodos en escenarios multivariados, donde la forma cerrada de la distancia de Wasserstein para distribuciones gaussianas podría representar una ventaja computacional y estadística frente al enfoque empírico. De igual manera, sería relevante considerar un marco experimental más amplio que incluya series de tiempo provenientes de dominios específicos de aplicación, con el fin de evaluar el desempeño de los métodos en contextos reales y dinámicas más complejas.

REFERENCIAS

- [1] Keilor Rojas-Jimenez. *Análisis de Series de Tiempo*. Disponible en bookdown.org. 2022. URL: https://bookdown.org/keilor_rojas/CienciaDatos/analisis-de-series-de-tiempo.html.
- [2] Jiancheng Sun et al. “Univariate time series classification using information geometry”. En: *Information Sciences* 502 (2019). Available online 31 May 2019, págs. 553-567. DOI: [10.1016/j.ins.2019.05.056](https://doi.org/10.1016/j.ins.2019.05.056).
- [3] Clément Péalat, Guillaume Bouleux y Vincent Cheutet. “Improved time series clustering based on new geometric frameworks”. En: *Pattern Recognition* 122 (2022), pág. 108352. DOI: [10.1016/j.patcog.2021.108352](https://doi.org/10.1016/j.patcog.2021.108352).
- [4] Jiancheng Sun et al. “Latent Network Construction for Univariate Time Series Based on Variational Auto-Encode”. En: *Entropy* 23.8 (2021), pág. 1071. DOI: [10.3390/e23081071](https://doi.org/10.3390/e23081071). URL: <https://www.mdpi.com/1099-4300/23/8/1071>.
- [5] Johann Faouzi. *Time Series Classification: A Review of Algorithms and Implementations*. Mar. de 2024. DOI: [10.5772/intechopen.1004810](https://doi.org/10.5772/intechopen.1004810).
- [6] Benjamin S. Baumer y Biviana Marcela Suárez Sierra. *tidychangepoint: a unified framework for analyzing changepoint detection in univariate time series*. 2025. arXiv: [2407.14369](https://arxiv.org/abs/2407.14369) [stat.ME]. URL: <https://arxiv.org/abs/2407.14369>.
- [7] Samaneh Aminikhanghahi y Diane J. Cook. “A Survey of Methods for Time Series Change Point Detection”. En: *Knowledge and Information Systems* 51.2 (mayo de 2017), págs. 339-367. ISSN: 0219-1377. DOI: [10.1007/s10115-016-0987-z](https://doi.org/10.1007/s10115-016-0987-z). URL: <https://doi.org/10.1007/s10115-016-0987-z>.
- [8] Xian Chen y Weichi Wu. *Bayesian online collective anomaly and change point detection in fine-grained time series*. 2025. arXiv: [2508.06385](https://arxiv.org/abs/2508.06385) [stat.ME]. URL: <https://arxiv.org/abs/2508.06385>.
- [9] Muktesh Gupta, Rajesh Wadhvani y Akhtar Rasool. “Comprehensive analysis of change-point dynamics detection in time series data: A review”. En: *Expert Systems with Applications* 248 (ene. de 2024), pág. 123342. ISSN: 0957-4174. DOI: [10.1016/j.eswa.2024.123342](https://doi.org/10.1016/j.eswa.2024.123342). URL: <https://doi.org/10.1016/j.eswa.2024.123342>.

- [10] Aditya Pushkar et al. “A Comparative Study on Change-Point Detection Methods in Time Series Data”. En: *2022 2nd International Conference on Intelligent Technologies (CONIT)*. Karnataka, India: IEEE, 2022, págs. 1-6. DOI: [10.1109/CONIT55038.2022.9847877](https://doi.org/10.1109/CONIT55038.2022.9847877).
- [11] Biviana Marcela Suárez Sierra, Arrigo Coen y Carlos Alberto Taimal. “Genetic algorithm with a Bayesian approach for multiple change-point detection in time series of counting exceedances for specific thresholds”. En: *Journal of the Korean Statistical Society* 52.4 (oct. de 2023), págs. 982-1024. ISSN: 2005-2863. DOI: [10.1007/s42952-023-00227-2](https://doi.org/10.1007/s42952-023-00227-2). URL: <https://doi.org/10.1007/s42952-023-00227-2>.
- [12] Chak Fung Choi et al. *Predicting Future Change-points in Time Series*. 2024. arXiv: [2405.09485](https://arxiv.org/abs/2405.09485) [stat.ME]. URL: <https://arxiv.org/abs/2405.09485>.
- [13] Stephan van Staden. “Pointwise Metrics for Clustering Evaluation”. En: *arXiv preprint arXiv:2405.10421* (mayo de 2024). URL: <https://arxiv.org/abs/2405.10421>.
- [14] Charles Truong, Laurent Oudre y Nicolas Vayatis. “Selective review of offline change point detection methods”. En: *Signal Processing* 167 (2020), pág. 107299. ISSN: 0165-1684. DOI: <https://doi.org/10.1016/j.sigpro.2019.107299>. URL: <https://www.sciencedirect.com/science/article/pii/S0165168419303494>.
- [15] Claudia Czado y Axel Munk. *Nonparametric Validation of Similar Distributions and Assessment of Goodness of Fit*. <https://doi.org/10.1111/1467-9868.00119>. Journal of the Royal Statistical Society: Series B (Statistical Methodology), 60(1), 223–241. 1998.
- [16] Claudia Czado y Axel Munk. *Assessing the similarity of distributions—finite sample performance of the empirical Mallows statistic*. <https://doi.org/10.1080/00949659808811898>. Journal of Statistical Computation and Simulation, 60(4), 319–346. 1998.
- [17] E. del Barrio et al. *Central limit theorem and bootstrap procedure for Wasserstein’s variations with an application to structural relationships between distributions*. Ene. de 2019.
- [18] Kevin C. Cheng et al. *Optimal Transport Based Change Point Detection and Time Series Segment Clustering*. 2020. arXiv: [1911.01325](https://arxiv.org/abs/1911.01325) [eess.SP]. URL: <https://arxiv.org/abs/1911.01325>.
- [19] V. Masarotto, V. Panaretos e Y. Zemel. *Procrustes Metrics on Covariance Operators and Optimal Transportation of Gaussian Processes*. Ene. de 2018. DOI: [10.1080/01621459.2017.1328355](https://doi.org/10.1080/01621459.2017.1328355).
- [20] J. Stark et al. “Takens embedding theorems for forced and stochastic systems”. En: *Nonlinear Analysis: Theory, Methods & Applications* 30.8 (1997). Proceedings of the Second World Congress of Nonlinear Analysts, págs. 5303-5314. ISSN: 0362-546X. DOI: [https://doi.org/10.1016/S0362-546X\(96\)00149-6](https://doi.org/10.1016/S0362-546X(96)00149-6). URL: <https://www.sciencedirect.com/science/article/pii/S0362546X96001496>.
- [21] Changliang Zou et al. “Nonparametric Maximum Likelihood Approach to Multiple Change-Point Problems”. En: *The Annals of Statistics* 42.3 (2014), págs. 970-1002. DOI: [10.1214/14-AOS1210](https://doi.org/10.1214/14-AOS1210).
- [22] Lucien Birgé y Pascal Massart. *A Generalized Cp Criterion for Gaussian Model Selection*. Inf. téc. Prépublication 647. Technical report. Universités de Paris 6 et Paris 7, 2001, pág. 39. URL: http://massart.pascal.free.fr/Site/publications_files/Cp.pdf.
- [23] Adeiza James Onumanyi et al. “AutoElbow: An Automatic Elbow Detection Method for Estimating the Number of Clusters in a Dataset”. En: *Applied Sciences* 12.15 (2022), pág. 7515. ISSN: 2076-3417. DOI: [10.3390/app12157515](https://doi.org/10.3390/app12157515). URL: <https://doi.org/10.3390/app12157515>.